


# 확률적 경사 하강법

경제학과 2015231035 하지민



# 점진적인 학습

## 경사 하강법 (Gradient Descent)

함수의 기울기(경사)를 구하여 기울기의 절댓값이 낮은 쪽으로 이동시켜 극값(최적값)을 찾는 방법  
즉, 비용함수를 최소화 하기 위해 경사를 반복적으로 하강해가면서 파라미터를 조정해 나가는 것

## 확률적 경사 하강법 (Stochastic Gradient Descent)


랜덤으로 단 한 개의 데이터를 추출하여(배치 크기 1) 기울기를 얻어냄. 이러한 과정을 반복해서 학습하여 최적점을 찾아내는 것이 확률적 경사 하강법

### **\*\*배치(batch)\*\***


모델 학습의 반복 1회, 즉 경사 업데이트 1회에 사용되는 트레이닝 데이터의 집합


### **\*\*에포크(epoch)\*\***

확률적 경사 하강법에서 훈련 세트를 한 번 모두 사용하는 과정

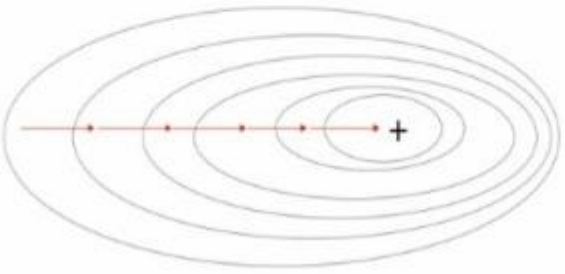
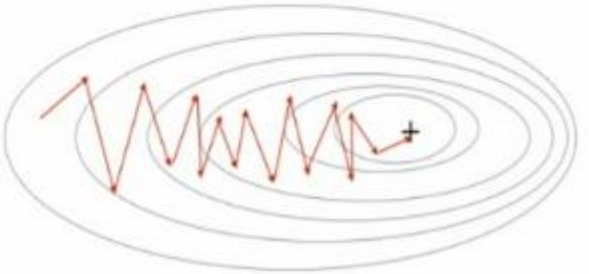


# 경사 하강법






# 경사 하강법 비교

	경사하강법	확률적 경사하강법
1회의 학습에 사용되는 데이터	모든 데이터 사용	랜덤으로 추출된 1개의 데이터 사용(중복 선택 가능)
반복에 따른 정확도	학습이 반복 될 수록 최적해에 근접	학습이 반복 될 수록 최적해에 근접
노이즈	거의 없음	비교적 노이즈가 심함
해를 찾는 과정의 이미지 비교	<div>Gradient Descent </div>	<div>Stochastic Gradient Descent </div>

한 번 학습할 때 마다 모든 데이터를 계산하여 최적의 한 스텝을 나아가는 경사 하강법과 달리, 확률적 경사 하강법은 랜덤하게 추출한 하나의 데이터만 계산하여 빠르게 다음 스텝으로 넘어 감.

그 결과 더 빠르게 최적점을 찾을 수 있게 되었지만 그 정확도는 낮아짐



# 손실 함수


## 손실 함수

예상한 값과 실제 타깃값의 차이를 함수로 정의한 것(비용함수, 목적함수로도 불림)

평균 제곱 오차를 많이 사용.(선형회귀 모델에 적합)



$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

차이가 음수이든 양수이든 상관없이 차이의 크기만 고려하고자 하기 때문




# 손실 함수

최적의 가중치 = 예측값과 실제 값의 차이를 최소화하는 가중치 = 손실 함수 값을 최솟값으로 만드는 가중치



접선의 기울기가 음수이면  $w$ 를 증가시키고, 접선의 기울기가 양수이면  $w$ 를 감소시킴  
 $W_{\text{new}} = w - \text{접선 기울기(손실함수 미분값)}$



# 손실 함수에서 가중치와 절편의 업데이트

가중치에 대해 제곱오차 미분

오차역전파

절편에 대해 제곱오차 미분

$$SE = (y - \hat{y})^2 \\ = (y - (wx + b))^2$$

$$\textcircled{1} \hat{y} = wx + b$$

$$\textcircled{2} \frac{dSE}{dw} = \frac{d}{dw} (y - \hat{y})^2 = 2(y - \hat{y}) \left( -\frac{d}{dw} \hat{y} \right) \\ = 2(y - \hat{y})(-x) = -2(y - \hat{y})x$$

$$W_{new} = W - (-2(y - \hat{y})x)$$


\* 여기서 2는 이동하는 정도에만 영향  
방향성에는 영향 X  
2를 없애줘도 가중치 찾는게 무방

$$W_{new} = W - \frac{dSE}{dw} = W + (y - \hat{y})x$$

$$\textcircled{1} \hat{y} = wx + b$$

$$\textcircled{2} \frac{dSE}{db} = \frac{d}{db} (y - \hat{y})^2 = 2(y - \hat{y}) \left( -\frac{d}{db} \hat{y} \right) \\ = 2(y - \hat{y})(-1) = -2(y - \hat{y})$$

$$b_{new} = b - \frac{dSE}{db} = b + (y - \hat{y})$$



# 로지스틱 손실 함수

## 로지스틱 손실 함수

이진분류를 위한 모델


다중 분류일 경우 크로스엔트로피 손실 함수 사용

$$L = -(y \log(a) + (1 - y) \log(1 - a))$$

	$L$
$y = 1$ (양성클래스)	$-\log(a)$
$y = 0$ (음성클래스)	$-\log(1 - a)$

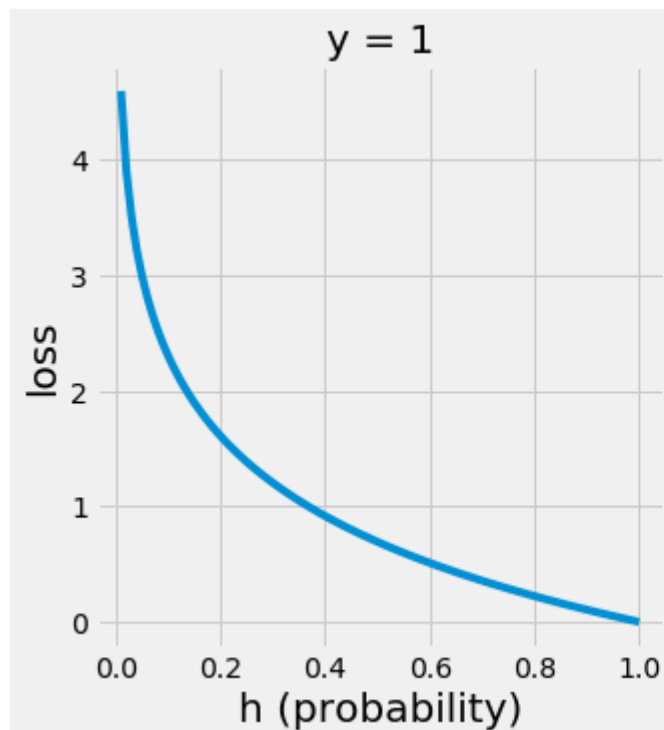
이 때  $a$ 는 활성화 함수의 결과 값으로 0~1사이의 범위를 갖는다.






# 로지스틱 손실 함수

양성클래스




음성클래스



L의 값이 최소화 될 때, 샘플이 올바르게 분류되는 방향으로 a 값이 구해짐

즉, L의 값이 최소화될 때 로지스틱 회귀 모델 목표가 달성



## 로지스틱 손실 함수

	제곱 오차의 미분	로지스틱 손실 함수의 미분
가중치에 대한 미분	$\frac{\partial SE}{\partial w} = -(y - \hat{y})x$	$\frac{\partial L}{\partial w} = -(y - a)x$
절편에 대한 미분	$\frac{\partial SE}{\partial b} = -(y - \hat{y})1$	$\frac{\partial L}{\partial b} = -(y - a)1$

제곱오차의 미분결과와 매우 유사

가중치와 절편을 업데이트하는 방법은 기존 가중치에 미분값을 빼는 것

$$w = w - \left( \frac{\partial L}{\partial w} \right) = w + (y - a)x$$

$$b = b - \left( \frac{\partial L}{\partial b} \right) = b + (y - a)1$$